Découvrons la programmation asynchrone en quelques exemples

Arnaud Calmettes (nohar)

9 octobre 2015

Ça veut dire quoi, *asynchrone* ?

En un mot comme en cent, un programme qui fonctionne de façon *asychrone*, c'est un programme qui évite au maximum de passer du temps à *attendre sans rien faire*, et qui s'arrange pour *s'occuper autant que possible pendant qu'il attend*. Cette façon d'optimiser le temps d'attente est tout à fait naturelle pour nous. Par exemple, on peut s'en rendre compte en observant le travail d'un serveur qui monte votre commande dans un *fast food*.

De façon synchrone :

- Préparer le hamburger :
  - Demander le hamburger en cuisine.
  - Attendre le hamburger (1 minute).
  - Récupérer le hamburger et le poser sur le plateau.
- Préparer les frites :
  - Mettre des frites à chauffer.
  - Attendre que les frites soient cuites (2 minutes).
  - Récupérer des frites et les poser sur le plateau.
- Préparer la boisson :
  - Placer un gobelet dans la machine à soda.
  - Remplir le gobelet (30 secondes).
  - Récupérer le gobelet et le poser sur le plateau.

En gros, si notre employé de *fast food* était synchrone, il mettrait 3 minutes et 30 secondes pour monter votre commande.

Alors que de façon asynchrone :

- Demander le hamburger en cuisine.
- Mettre les frites à chauffer.
- Placer un gobelet dans la machine à soda et le mettre à remplir.
- Après 30 secondes : Récupérer le gobelet et le poser sur le plateau.
- Après 1 minute : Récupérer le hamburger et le poser sur le plateau.
- Après 2 minutes : Récupérer les frites et les poser sur le plateau.

En travaillant de façon asynchrone, notre employé de *fast food* monte maintenant votre commande en 2 minutes. Mais ça ne s'arrête pas là !

— **Une commande `A` est confiée à l'employé**
— Demander le burger pour `A` en cuisine
— Mettre les frites à chauffer.
— Placer un gobelet dans la machine à soda pour `A`.
— Après 30 secondes : Récupérer le gobelet de `A` et le poser sur son plateau
— **Une nouvelle commande `B` est prise et confiée à l'employé**
— Demander le burger pour `B` en cuisine
— Placer un gobelet dans la machine à soda pour `B`.
— Après 1 minute : Le burger de `A` est prêt, le poser sur son plateau.
— La boisson de `B` est remplie, la poser sur son plateau.
— Après 1 minute 40 : Le burger de `B` est prêt, le poser sur son plateau.
— Après 2 minutes : Les frites sont prêtes, servir `A` et `B`

Toujours en 2 minutes, l'employé asynchrone vient cette fois de servir 2 clients. Si vous vous mettez à la place du client `B` qui aurait dû attendre que l'employé finisse de monter la commande de `A` avant de s'occuper de la sienne dans un schéma synchrone, celui-ci a été servi en 1 minute 30 au lieu d'attendre 6 minutes 30.

Pensez-y la prochaine fois que vous irez manger dans un fast-food, et observez les serveurs. Leur boulot vous semblera d'un coup beaucoup plus compliqué qu'il n'y paraît !

En informatique, il existe un type de tâche qui impose aux programmes d'attendre sans rien faire : ce sont les *entrées/sorties* (ou *IO*). Nous verrons dans cet article que la programmation asynchrone est une façon extrêmement puissante d'implémenter des programmes qui réalisent plus d'IO que de calcul (comme une application de messagerie instantanée, par exemple).

Exemple n°1 : Une boucle événementielle, c'est essentiel

La notion fondamentale autour de laquelle `asyncio` a été construite est celle de *coroutine*.

Une coroutine est une tâche qui peut décider de se suspendre elle-même au moyen du mot-clé `yield`, et attendre jusqu'à ce que le code qui la contrôle décide de lui rendre la main en *itérant* dessus.

On peut imaginer, par exemple, écrire la fonction suivante :

```
def tic_tac():
    print("Tic")
    yield
    print("Tac")
    yield
    return "Boum!"
```

Cette fonction, puisqu'elle utilise le mot-clé `yield`, définit une *coroutine*[1]. Si on l'invoque, la fonction `tic_tac` retourne une tâche prête à être exécutée, mais n'exécute pas les instructions qu'elle contient.

```
>>> task = tic_tac()
>>> task
<generator object tic_tac at 0x7fe157023280>
```

1. En toute rigueur il s'agit d'un *générateur*, mais comme nous avons pu l'observer dans un précédent article, les générateurs de Python sont implémentés comme de véritables coroutines.

En termes de vocabulaire, on dira que notre fonction `tic_tac` est une *fonction coroutine*, c'est-à-dire une fonction qui **construit une coroutine**. La coroutine est contenue ici dans la variable `task`.

Nous pouvons maintenant exécuter son code jusqu'au prochain `yield`, en nous servant de la fonction standard `next()` :

```
>>> next(task)
Tic
>>> next(task)
Tac
>>> next(task)
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
StopIteration: Boum!
```

Lorsque la tâche est terminée, une exception `StopIteration` est levée. Celle-ci contient la valeur de retour de la coroutine. Jusqu'ici, rien de bien sorcier. Dès lors, on peut imaginer créer une petite boucle pour exécuter cette coroutine jusqu'à épuisement :

```
>>> task = tic_tac()
>>> while True:
...     try:
...         next(task)
...     except StopIteration as stop:
...         print("valeur de retour:", repr(stop.value))
...         break
...
Tic
Tac
valeur de retour: 'Boum!'
```

Afin de nous affranchir de la sémantique des itérateurs de Python, créons une classe `Task` qui nous permettra de manipuler nos coroutines plus aisément :

```
STATUS_NEW = 'NEW'
STATUS_RUNNING = 'RUNNING'
STATUS_FINISHED = 'FINISHED'
STATUS_ERROR = 'ERROR'

class Task:
    def __init__(self, coro):
        self.coro = coro  # Coroutine à exécuter
        self.name = coro.__name__
        self.status = STATUS_NEW  # Statut de la tâche
        self.return_value = None  # Valeur de retour de la coroutine
        self.error_value = None  # Exception levée par la coroutine

    # Exécute la tâche jusqu'à la prochaine pause
    def run(self):
        try:
            # On passe la tâche à l'état RUNNING et on l'exécute jusqu'à
```

```
            # la prochaine suspension de la coroutine.
            self.status = STATUS_RUNNING
            next(self.coro)
        except StopIteration as err:
            # Si la coroutine se termine, la tâche passe à l'état FINISHED
            # et on récupère sa valeur de retour.
            self.status = STATUS_FINISHED
            self.return_value = err.value
        except Exception as err:
            # Si une autre exception est levée durant l'exécution de la
            # coroutine, la tâche passe à l'état ERROR, et on récupère
            # l'exception pour laisser l'utilisateur la traiter.
            self.status = STATUS_ERROR
            self.error_value = err

    def is_done(self):
        return self.status in {STATUS_FINISHED, STATUS_ERROR}

    def __repr__(self):
        result = ''
        if self.is_done():
            result = " ({!r})".format(self.return_value or self.error_value)

        return "<Task '{}' [{}]{}>".format(self.name, self.status, result)
```

Son fonctionnement est plutôt simple. Réimplémentons notre boucle en nous servant de cette classe :

```
>>> task = Task(tic_tac())
>>> task
<Task 'tic_tac' [NEW]>
>>> while not task.is_done():
...     task.run()
...     print(task)
...
Tic
<Task 'tic_tac' [RUNNING]>
Tac
<Task 'tic_tac' [RUNNING]>
<Task 'tic_tac' [FINISHED] ('Boom!')>
>>> task.return_value
'Boom!'
```

Bien. Nous avons une classe qui nous permet de manipuler des tâches en cours d'exécution, ces tâches étant implémentées sous la forme de coroutines. Il ne nous reste plus qu'à trouver un moyen d'exécuter plusieurs coroutines de façon **concurrente**, c'est-à-dire en parallèle les unes des autres. En effet, tout l'intérêt de la programmation asynchrone est d'être capable d'occuper le programme pendant qu'une tâche donnée est en attente d'un événement.

Pour cela, il suffit de construire une *file d'attente* de tâches à exécuter. En Python, l'objet le plus pratique pour modéliser une file d'attente est la classe standard `collections.deque` (*double-ended*

queue). Cette classe possède les mêmes méthodes que les listes, auxquelles viennent s'ajouter :

— `appendleft()` pour ajouter un élément au tout début de la liste,
— `popleft()` pour retirer (et retourner) le premier élément de la liste.

Ainsi, il suffit ajouter les éléments à une extrémité de la file (`append()`), et consommer ceux de l'autre extrémité (`popleft()`). On pourrait arguer qu'il est possible d'ajouter des éléments n'importe où dans une liste avec la méthode `insert()`, mais la classe `deque` est vraiment *faite pour* créer des files et des piles : ses opérations aux extrémités sont bien plus efficaces que la méthode `insert()`.

Essayons d'exécuter en parallèle deux instances de notre coroutine `tic_tac` :

```
>>> from collections import deque
>>> running_tasks = deque()
>>> running_tasks.append(Task(tic_tac()))
>>> running_tasks.append(Task(tic_tac()))
>>> while running_tasks:
...     # On récupère une tâche en attente et on l'exécute
...     task = running_tasks.popleft()
...     task.run()
...     if task.is_done():
...         # Si la tâche est terminée, on l'affiche
...         print(task)
...     else:
...         # La tâche n'est pas finie, on la replace au bout
...         # de la file d'attente
...         running_tasks.append(task)
...
Tic
Tic
Tac
Tac
<Task 'tic_tac' [FINISHED] ('Boom!')>
<Task 'tic_tac' [FINISHED] ('Boom!')>
```

Voilà qui est intéressant : la sortie des deux coroutines est entremêlée ! Cela signifie que les deux tâches ont été exécutées simultanément, de façon **concurrente**.

Nous avons tout ce qu'il nous faut pour modéliser une boucle événementielle, c'est-à-dire une boucle qui s'occupe de programmer l'exécution et le réveil des tâches dont elle a la charge. Implémentons celle-ci dans la classe `Loop` suivante :

```
from collections import deque

class Loop:
    def __init__(self):
        self._running = deque()

    def _loop(self):
        task = self._running.popleft()
        task.run()
        if task.is_done():
```

```
            print(task)
            return
        self.schedule(task)

    def run_until_empty(self):
        while self._running:
            self._loop()

    def schedule(self, task):
        if not isinstance(task, Task):
            task = Task(task)
        self._running.append(task)
        return task
```

Vérifions :

```
>>> def spam():
...     print("Spam")
...     yield
...     print("Eggs")
...     yield
...     print("Bacon")
...     yield
...     return "SPAM!"
...
>>> event_loop = Loop()
>>> event_loop.schedule(tic_tac())
>>> event_loop.schedule(spam())
>>> event_loop.run_until_empty()
Tic
Spam
Tac
Eggs
<Task 'tic_tac' [FINISHED] ('Boom!')>
Bacon
<Task 'spam' [FINISHED] ('SPAM!')>
```

Tout fonctionne parfaitement. Dotons tout de même notre classe `Loop` d'une dernière méthode pour exécuter la boucle jusqu'à épuisement d'une coroutine en particulier :

```
class Loop:
    # ...
    def run_until_complete(self, task):
        task = self.schedule(task)
        while not task.is_done():
            self._loop()
```

Testons-la :

```
>>> event_loop = Loop()
>>> event_loop.run_until_complete(tic_tac())
```

```
Tic
Tac
<Task 'tic_tac' [FINISHED] ('Boom!')>
```

Pas de surprise.

Toute la programmation asynchrone repose sur ce genre de boucle qui sert en fait d'*ordonnanceur* aux tâches en cours d'exécution. Pour vous en convaincre, regardez ce bout de code qui utilise `asyncio` :

```
>>> import asyncio
>>> loop = asyncio.get_event_loop()
>>> loop.run_until_complete(tic_tac())
Tic
Tac
'Boom!'
>>> loop.run_until_complete(asyncio.wait([tic_tac(), spam()]))
Spam
Tic
Eggs
Tac
Bacon
({Task(<tic_tac>)<result='Boom!'>, Task(<spam>)<result='SPAM!'>}, set())
```

Drôlement familier, n'est-ce pas ? Ne bloquez pas sur la fonction `asyncio.wait` : il s'agit simplement d'une coroutine qui sert à lancer plusieurs tâches en parallèle et attendre que celles-ci se terminent avant de retourner. Nous la reprogrammerons nous-mêmes très bientôt. ;)

Exemple n°2 : Exécuter des tâches concurrentes

Dans le précédent exemple, nous avons déclenché l'exécution concurrente de deux coroutines en les programmant explicitement dans la boucle :

```
>>> event_loop = Loop()
>>> event_loop.schedule(Task(tic_tac()))
>>> event_loop.schedule(Task(spam()))
>>> event_loop.run_until_empty()
# les deux coroutines s'exécutent en parallèle.
```

Ce petit morceau de code nous a permis de prouver qu'avec une boucle événementielle et des coroutines, on avait tout ce qu'il nous fallait pour définir un modèle d'exécution concurrent.

Cependant, dans la pratique, on ne devrait pas avoir à manipuler directement la boucle pour réaliser quelque chose d'aussi simple que le lancement d'une tâche parallèle. En fait, **nos classes `Loop` et `Task` sont l'implémentation à bas niveau d'un petit framework asynchrone**, le programmeur ne devrait jamais avoir à y toucher à part pour lancer le programme asynchrone qu'il a écrit dans des coroutines.

Si l'on se réfère aux autres modes de concurrence :

— On peut lancer un *thread* et attendre la fin de l'exécution de celui-ci depuis n'importe quel *thread* en cours d'exécution.

— On peut créer, attendre ou arrêter un processus depuis n'importe quel processus en cours d'exécution.

Qu'il s'agisse de *threads* ou de processus, ces actions ne requièrent à aucun moment d'interagir directement avec l'ordonnanceur de votre système d'exploitation (OS). [2]

De façon analogue, **on devrait pouvoir lancer, attendre la fin de l'exécution, ou annuler une coroutine depuis n'importe quelle coroutine en cours d'exécution**, sans avoir à toucher directement à la boucle événementielle.

Commençons par chercher le moyen de faire appel à une coroutine depuis une tâche en cours d'exécution. Rappelons d'abord que la syntaxe `yield from` introduite dans le langage depuis Python 3.3 nous permet déjà de passer la main à une autre coroutine. Par exemple, dans le code suivant, la coroutine `example` utilise cette syntaxe pour laisser temporairement la main à la coroutine `subtask` :

```
def example():
    print("Tâche 'example'")
    print("Lancement de la tâche 'subtask'")
    yield from subtask()
    print("Retour dans 'example'")
    for _ in range(3):
        print("(example)")
        yield

def subtask():
    print("Tâche 'subtask'")
    for _ in range(2):
        print("(subtask)")
        yield
```

Vérifions :

```
>>> event_loop = Loop()
>>> event_loop.run_until_complete(example())
Tâche 'example'
Lancement de la tâche 'subtask'
Tâche 'subtask'
(subtask)
(subtask)
Retour dans 'example'
(example)
(example)
(example)
<Task 'example' [FINISHED] (None)>
```

Ainsi, Python nous fournit déjà nativement un élément de syntaxe pour *lancer une tâche de façon séquentielle* à l'intérieur d'une coroutine. Mais ce n'est pas tout à fait ce que nous voulons : notre but, ici, est de réussir à lancer la coroutine `subtask` de façon qu'elle s'exécute *en parallèle* de la coroutine `example`, et non d'attendre que `subtask` soit terminée pour reprendre l'exécution de `example`.

2. D'ailleurs, le noyau de l'OS est justement là pour vous empêcher de toucher vous-même à l'ordonnanceur !

Pour ce faire, nous allons tirer parti d'une particularité des coroutines que nous avons découverte dans cet article : il est possible d'échanger des messages avec une coroutine en cours d'exécution.

Pour bien comprendre ce qui va suivre, continuons, si vous le voulez bien, notre parallèle avec le fonctionnement d'un système d'exploitation. Lorsqu'un processus [3] `A` a besoin d'exécuter un programme `B` dans un processus concurrent, celui-ci réalise ce que l'on appelle un *appel système*, c'est-à-dire qu'il *envoie un message* à l'OS pour lui demander de bien vouloir lancer le nouveau programme `B`. [4] Dans la pratique, cet *appel système* ressemble à s'y méprendre à n'importe quel appel de fonction. **L'idée-clé, c'est que le processus peut *communiquer* avec le noyau du système d'exploitation en échangeant des *messages* avec lui.**

Nous allons maintenant transposer cette notion à notre cas : nous voulons réussir à faire communiquer la boucle événementielle avec les coroutines qu'elle exécute grâce à des *messages*.

Rappelons rapidement que l'on peut envoyer une donnée à une coroutine au moment où celle-ci se suspend, en utilisant la méthode `send` des coroutines :

```
>>> def receiver():
...     while True:
...         data = yield
...         print('received:', repr(data))
...
>>> coro = receiver()
>>> next(coro)  # La coroutine doit être démarrée pour recevoir des données
>>> coro.send("spam")
received: 'spam'
>>> coro.send("eggs")
received: 'eggs'
>>> coro.send("bacon")
received: 'bacon'
```

À l'opposé, on peut également envoyer des données depuis une coroutine en passant un argument au mot-clé `yield` :

```
>>> def sender():
...     while True:
...        yield "spam"
...        yield "eggs"
...        yield "bacon"
...
>>> coro = sender()
>>> coro.send(None)  # Équivalent à next(coro)
'spam'
>>> coro.send(None)
'eggs'
>>> coro.send(None)
'bacon'
```

On peut donc parfaitement imaginer simuler un appel système :

3. Un *processus* peut être vu comme **un programme en cours d'exécution**.
4. Ce comportement n'est pas exclusif aux processus : de la même façon, un *thread* `A` envoie au noyau un appel système lorsqu'il veut lancer un nouveau *thread* `B`.

```
>>> def requester():
...     data = yield 'REQUÊTE'
...     print('data:', repr(data))
...     return
...
>>> coro = requester()
>>> coro.send(None)  # On lance la coroutine
'REQUÊTE'
```

La coroutine vient de nous envoyer un message. Répondons-lui.

```
>>> coro.send('RÉPONSE')
data: 'RÉPONSE'
```

Comme vous le constatez, la syntaxe de Python rend assez intuitif le fait que notre coroutine peut envoyer des requêtes à son environnement d'exécution, et se suspendre jusqu'à ce qu'on lui envoie le résultat de cette requête.

Pour que ces messages soient transmis par notre classe `Task` du premier exemple, nous devons l'accomoder un petit peu :

```
class Task:
    def __init__(self):
        # ...
        self.msg = None

    def run(self):
        try:
            self.status = STATUS_RUNNING
            return self.coro.send(self.msg)
        # ...
```

Ainsi, on peut envoyer un message à une tâche simplement en affectant son attribut `task.msg`, et la méthode `task.run()` retourne maintenant tous les messages que la coroutine pourrait `yield`-er.

Reste à déterminer la forme des messages grâce auxquels la coroutine peut faire appel à sa boucle d'exécution. De manière similaire aux appels système, on peut par exemple décider que ces messages seront un tuple sous la forme suivante :

```
(TYPE_APPEL, arguments)
```

Par exemple, pour demander à la boucle événementielle de lancer une ou plusieurs coroutines en parallèle, le message serait :

```
('SCHEDULE', [task1, task2, ...])
```

Modifions la méthode `_loop()` de notre boucle pour qu'elle réagisse à ces messages :

```
CALL_SCHEDULE = 'SCHEDULE'

class Loop:
    def __init__(self):
        self._running = deque()
```

```
    def _loop(self):
        task = self._running.popleft()
        msg = task.run()  # Réception du message

        if task.is_done():
            print(task)
        else:
            self.schedule(task)

        if not msg:
            return

        msg_type, args = msg
        if msg_type == CALL_SCHEDULE:
            # Si le message est un ordre d'exécuter des tâches parallèles,
            # on programme ces tâches et on les retourne à la tâche
            # appelante.
            task.msg = tuple(self.schedule(subtask) for subtask in args)
        else:
            raise RuntimeError("Message inconnu : {}".format(msg_type))
```

On peut maintenant abstraire ce message derrière une coroutine que nous appellerons `ensure_future()`, pour respecter la même nomenclature qu'`asyncio` :

```
def ensure_future(task):
    # L'appel à CALL_SCHEDULE retourne un tuple à un seul élément dans ce cas
    (task,) = yield CALL_SCHEDULE, [task]
    return task
```

Nous disposons désormais de deux façons d'exécuter une sous-tâche depuis une coroutine :

— `yield from subtask()` : lance l'exécution d'une coroutine de façon *séquentielle*, c'est-à-dire en lui laissant la main jusqu'à ce que celle-ci se soit terminée.
— `yield from ensure_future(subtask())` : lance l'exécution d'une coroutine *en parallèle*.

Ainsi, si nous modifions notre coroutine `example()` définie plus haut en conséquence, nous pouvons vérifier que nos tâches sont bien exécutées de façon concurrente :

```
>>> def example():
...     print("Tâche 'example'")
...     print("Lancement de la tâche 'subtask'")
...     yield from ensure_future(subtask())
...     print("Retour dans 'example'")
...     for _ in range(3):
...         print("(example)")
...         yield
...
>>> event_loop = Loop()
>>> event_loop.run_until_complete(example())
Tâche 'example'
```

```
Lancement de la tâche 'subtask'
Retour dans 'example'
(example)
Tâche 'subtask'
(subtask)
(example)
(subtask)
(example)
<Task 'subtask' [FINISHED] (None)>
<Task 'example' [FINISHED] (None)>
```

Magique, n'est-ce pas ?

Par contre, une fois que notre coroutine est lancée, nous n'avons pas tout à fait le contrôle de son exécution. Par exemple, si nous rendions la tâche `subtask` plus longue qu'`example`, celle-ci lui « survivrait » :

```
>>> def subtask():
...     print("Tâche 'subtask'")
...     for _ in range(5):
...         print("(subtask)")
...         yield
...
>>> event_loop.run_until_complete(example())
Tâche 'example'
Lancement de la tâche 'subtask'
Retour dans 'example'
(example)
Tâche 'subtask'
(subtask)
(example)
(subtask)
(example)
(subtask)
<Task 'example' [FINISHED] (None)>
```

L'exécution s'arrête avec la fin de la coroutine `example`, mais la coroutine `subtask`, elle, n'a pas fini. Elle est encore suspendue dans la boucle, à l'état de zombie alors que le reste du programme est terminé. Vidons ce qu'il reste dans la boucle événementielle :

```
>>> event_loop.run_until_empty()
(subtask)
(subtask)
<Task 'subtask' [FINISHED] (None)>
```

Que faire si nous ne voulons pas qu'une coroutine quitte avant une sous-tâche qu'elle aurait lancée en parallèle ?

Nous avons deux solutions. La première, dont nous nous contenterons dans cet exemple, serait de pouvoir *annuler* une tâche en cours d'exécution. Il nous suffit pour cela de créer un nouvel état dans notre classe `Task` :

```
STATUS_CANCELLED = "CANCELLED"

class Task:

    # ...

    def cancel(self):
        if self.is_done():
            # Inutile d'annuler une tâche déjà terminée
            return
        self.status = STATUS_CANCELLED

    def is_cancelled(self):
        return self.status == STATUS_CANCELLED
```

Rajoutons un test dans la boucle événementielle pour déprogrammer les tâches annulées :

```
class Loop:

    # ...

    def _loop(self):
        task = self._running.popleft()

        if task.is_cancelled():
            # Si la tâche a été annulée,
            # on ne l'exécute pas et on "l'oublie".
            print(task)
            return

        # ... le reste de la méthode est identique
```

Il ne nous reste plus qu'une petite coroutine utilitaire à écrire pour annuler une tâche en cours d'exécution :

```
def cancel(task):
    # On annule la tâche
    task.cancel()
    # On laisse la main à la boucle événementielle pour qu'elle ait l'occasion
    # de prendre en compte l'annulation
    yield

def example():
    print("Tâche 'example'")
    print("Lancement de la tâche 'subtask'")
    sub = yield from ensure_future(subtask())
    print("Retour dans 'example'")
    for _ in range(3):
        print("(example)")
```

```
        yield
    yield from cancel(sub)
```

Vérifions :

```
>>> event_loop.run_until_complete(example())
Tâche 'example'
Lancement de la tâche 'subtask'
Retour dans 'example'
(example)
Tâche 'subtask'
(subtask)
(example)
(subtask)
(example)
(subtask)
<Task 'subtask' [CANCELLED]>
<Task 'example' [FINISHED] (None)>
```

Notre mécanisme d'annulation fonctionne comme prévu. Cela dit, on peut aussi imaginer tout simplement vouloir *attendre* de façon asynchrone que la sous-tâche ait terminé son exécution avant de quitter proprement…

Mais ça, je vous le garde pour le prochain exemple. ;)

Exemple n°3 : Attendre de façon asynchrone

À la fin du précédent exemple, nous avons implémenté un petit mécanisme *d'annulation* de tâches en cours d'exécution, qui permet d'éviter qu'une tâche *fille* survive à sa tâche *mère* en s'exécutant plus longtemps qu'elle. Cependant, il n'est peut-être pas toujours adéquat d'annuler brutalement une tâche. Par exemple, on peut imaginer que si celle-ci a des ressources à libérer, l'annuler risque de créer une fuite de mémoire…

Pour cette raison, on veut se donner un moyen *d'attendre* (de façon asynchrone) qu'une tâche ait fini de s'exécuter. En soi, cela n'est pas bien difficile, puisqu'il suffit de `yield`-er *tant que* l'événement que nous attendons ne s'est pas encore produit :

```
def example():
    print("Tâche 'example'")
    print("Lancement de la tâche 'subtask'")
    sub = yield from ensure_future(subtask())
    print("Retour dans 'example'")
    for _ in range(3):
        print("(example)")
        yield

    print("En attente de la fin de 'subtask'")
    while not sub.is_done() and not sub.is_cancelled():
        yield
    print("Ça y est, je peux quitter")
```

```
def subtask():
    print("Tâche 'subtask'")
    for _ in range(5):
        print("(subtask)")
        yield
```

Essayons :

```
>>> event_loop = Loop()
>>> event_loop.run_until_complete(example())
Tâche 'example'
Lancement de la tâche 'subtask'
Retour dans 'example'
(example)
Tâche 'subtask'
(subtask)
(example)
(subtask)
(example)
(subtask)
En attente de la fin de 'subtask'
(subtask)
(subtask)
<Task 'subtask' [FINISHED] (None)>
Ça y est, je peux quitter
<Task 'example' [FINISHED] (None)>
```

C'est plutôt enfantin, en fait.

Souvenez-vous maintenant de la coroutine `wait()` d'`asyncio` que nous avons aperçue dans l'exemple n°1 :

```
>>> import asyncio
>>> loop = asyncio.get_event_loop()
>>> loop.run_until_complete(asyncio.wait([tic_tac(), spam()]))
Tic
spam
Tac
eggs
bacon
({Task(<tic_tac>)<result='Boum!'>, Task(<spam>)<result='spam'>}, set())
```

Celle-ci permet d'attendre qu'une ou plusieurs tâches (lancées en parallèle) soient terminées avant de rendre la main. Sa valeur de retour se compose de deux ensembles (`set()`) :

— Le premier contient les tâches qui se sont terminées normalement ;
— Le second contient les tâches qui ont été annulées ou ont quitté sur une erreur.

C'est cette fonction que nous allons implémenter maintenant, parce qu'il serait vraiment dommage de se passer de sa souplesse d'utilisation !

En fait, le plus difficile dans cette fonction est surtout sa partie cosmétique. Pour avoir un comportement souple, il faut gérer le cas où les tâches passées à cette fonction sont des coroutines qui n'ont pas encore été lancées, ou bien des instances de la classe `Task` que la boucle événementielle aurait préalablement créées pour programmer leur exécution.

Voilà ce que cela peut donner :

```
def wait(tasks):
    # On commence par séparer les tâches en cours d'exécution des autres
    running, to_launch, finished, error = set(), set(), set(), set()
    for task in tasks:
        if isinstance(task, Task):
            if task.status == STATUS_FINISHED:
                finished.add(task)
            elif task.status in {STATUS_ERROR, STATUS_CANCELLED}:
                error.add(task)
            else:
                running.add(task)
        else:
            to_launch.add(task)

    # On lance les tâches qui ont besoin d'être lancées
    if to_launch:
        launched = yield CALL_SCHEDULE, to_launch
        running.update(launched)

    # On attend que tout le monde ait fini de s'exécuter
    while running:
        # On itère sur une copie immuable de l'ensemble 'running'
        # de façon à pouvoir modifier celui-ci sans risque dans la boucle
        for task in tuple(running):
            if not (task.is_done() or task.is_cancelled()):
                continue
            running.remove(task)
            if task.status == STATUS_FINISHED:
                finished.add(task)
            else:
                error.add(task)

        # S'il y a encore des tâches inachevées, on suspend la coroutine
        if running:
            yield

    return finished, error
```

Vérifions que nous avons bien un comportement similaire à `asyncio` :

```
>>> event_loop = Loop()
>>> event_loop.run_until_complete(wait([tic_tac(), spam()]))
Tic
```

```
Spam
Tac
Eggs
<Task 'tic_tac' [FINISHED] ('Boom!')>
Bacon
<Task 'spam' [FINISHED] ('SPAM!')>
<Task 'wait' [FINISHED] (({<Task 'tic_tac' [FINISHED] ('Boom!')>, <Task 'spam' [FINISHED] ('SP
```

Pas mal ! Et pour attendre une tâche préalablement démarrée ?

```
>>> def example():
...     print("Tâche 'example'")
...     print("Lancement de la tâche 'subtask'")
...     sub = yield from ensure_future(subtask())
...     print("Retour dans 'example'")
...     for _ in range(3):
...         print("(example)")
...         yield
...
...     print("En attente de la fin de 'subtask'")
...     yield from wait([sub])
...     print("Ça y est, je peux quitter")
...
>>> event_loop.run_until_complete(example())
Tâche 'example'
Lancement de la tâche 'subtask'
Retour dans 'example'
(example)
Tâche 'subtask'
(subtask)
(example)
(subtask)
(example)
(subtask)
En attente de la fin de 'subtask'
(subtask)
(subtask)
<Task 'subtask' [FINISHED] (None)>
Ça y est, je peux quitter
<Task 'example' [FINISHED] (None)>
```

Parfait. Nous venons d'implémenter notre première coroutine *d'attente asynchrone*. Celle-ci permet d'endormir une tâche pour ne la réveiller que lorsqu'une ou plusieurs autres tâches auront fini de s'exécuter. S'il y avait une seule chose à retenir de la programmation asynchrone, c'est bien ce mécanisme. C'est dans le fait de pouvoir dire, de façon tout à fait explicite : « je n'ai rien à faire pour le moment, réveillez-moi quand il se sera passé quelque chose d'intéressant », que réside tout l'intérêt de ce modèle d'exécution. Et ce genre d'attente est vraiment très fréquent en informatique !

Dans cet article, nous allons nous contenter de *simuler* ces tâches. Pour ce faire, il suffit de nous doter d'une coroutine d'endormissement que nous appellerons `async_sleep` :

```
# Nous utilisons les classes datetime et timedelta de la bibliothèque standard
# La première représente une date (précise), la seconde une durée.
from datetime import datetime, timedelta

def async_sleep(secs):

    # On calcule l'heure à laquelle on doit se réveiller
    wakeup = datetime.now() + timedelta(seconds=secs)

    # On laisse la main tant que l'heure de réveil n'est pas passée
    while datetime.now() < wakeup:
        yield
```

Vérifions rapidement qu'elle fonctionne :

```
>>> def sleep_test(secs, msg):
...     yield from async_sleep(secs)
...     print(msg)
...
>>> event_loop.run_until_complete(
...     wait([
...         sleep_test(3, 'trois'),
...         sleep_test(1, 'un'),
...         sleep_test(2, 'deux')
...     ])
... )
un
<Task 'sleep_test' [FINISHED] (None)>
deux
<Task 'sleep_test' [FINISHED] (None)>
trois
<Task 'sleep_test' [FINISHED] (None)>
<Task 'wait' [FINISHED] (...)>
```

Bien, nous avons maintenant tout ce qu'il nous faut pour modéliser un système asynchrone, comme notre employé de *fast food*, par exemple. Pour ramener cet exemple à des durées plus aisées à vérifier dans un programme, nous prendrons les temps suivants :

— Préparation d'un soda : 1 seconde,
— Préparation d'un hamburger : 3 secondes,
— Préparation d'une portion de frites : 4 secondes.

```
def get_soda():
    print("Remplissage du gobelet de soda")
    yield from async_sleep(1)
    print("Le soda est prêt")

def get_fries():
    print("Démarrage de la cuisson des frites")
    yield from async_sleep(4)
```

```
    print("Les frites sont prêtes")

def get_burger():
    print("Commande du burger en cuisine")
    yield from async_sleep(3)
    print("Le burger est prêt")
```

Nous n'avons plus qu'à modéliser notre serveur. Commençons par le concevoir de façon séquentielle :

```
def serve():
    start = datetime.now()
    yield from get_soda()
    yield from get_burger()
    yield from get_fries()
    print("Client servi en", datetime.now() - start)
```

Lorsqu'il attend "bêtement" que tout soit prêt, le serveur met 8 secondes à servir un client.

```
>>> event_loop.run_until_complete(serve())
Remplissage du gobelet de soda
Le soda est prêt
Commande du burger en cuisine
Le burger est prêt
Démarrage de la cuisson des frites
Les frites sont prêtes
Client servi en 0:00:08.000307
<Task 'serve' [FINISHED] (None)>
```

Alors que si nous le modélisons de façon asynchrone...

```
def async_serve():
    start = datetime.now()
    yield from wait([
        get_soda(),
        get_burger(),
        get_fries()
    ])
    print("Client servi en", datetime.now() - start)
```

... Le client est servi deux fois plus rapidement :

```
>>> event_loop.run_until_complete(async_serve())
Commande du burger en cuisine
Démarrage de la cuisson des frites
Remplissage du gobelet de soda
Le soda est prêt
<Task 'get_soda' [FINISHED] (None)>
Le burger est prêt
<Task 'get_burger' [FINISHED] (None)>
Les frites sont prêtes
<Task 'get_fries' [FINISHED] (None)>
```

```
Client servi en 0:00:04.000214
<Task 'async_serve' [FINISHED] (None)>
```

En modélisant cet exemple du début, nous venons de *construire* l'ensemble des outils et des primitives nécessaires à la programmation asynchrone. Cela dit, ce n'est encore que le début du voyage. Dans le prochain exemple, nous allons nous servir d'`asyncio` pour modéliser ce système d'une façon un peu plus réaliste, et découvrir que ce serveur de *fast food* représente un véritable problème d'optimisation d'un serveur asynchrone !

Exemple n°4 : Modélisons le serveur du *fast food* avec `asyncio`

Maintenant que nous avons fait le tour de toutes les primitives qui permettent la programmation asynchrone, il est temps pour nous d'étudier un système asynchrone programmé avec `asyncio`. Afin d'éviter d'alourdir le propos dans cet exemples, nous nous contenterons de notre exemple *fil rouge* : l'employé de fast food, en nous promettant d'aborder des applications réseau réelles dans un article ultérieur.

Commençons par implémenter celui-ci avec `asyncio`.

En réalité, vous n'allez pas tellement être dépaysés puisque le framework standard reprend plus ou moins la même API que celle que nous avons développé dans les trois derniers exemples. Les seules différences sont que :

- Toutes les coroutines doivent être décorées par `@asyncio.coroutine`, ce qui permet notamment de créer des coroutines qui ne `yield`-ent jamais.
- `wait()` devient `asyncio.wait()`.
- `async_sleep()` devient `asyncio.sleep()`.
- notre coroutine `ensure_future()` devient la **fonction** `asyncio.ensure_future()`. Notez toutefois que cette fonction n'existe que depuis Python 3.4.4. Dans les versions antérieures, celle-ci s'appelle `asyncio.async()`, mais son nom a été déprécié au profit de `ensure_future()` afin de libérer le mot-clé `async` pour Python 3.5.

```
import asyncio
from datetime import datetime

@asyncio.coroutine
def get_soda(client):
    print("  > Remplissage du soda pour {}".format(client))
    yield from asyncio.sleep(1)
    print("  < Le soda de {} est prêt".format(client))

@asyncio.coroutine
def get_fries(client):
    print("    > Démarrage de la cuisson des frites pour {}".format(client))
    yield from asyncio.sleep(4)
    print("    < Les frites de {} sont prêtes".format(client))

@asyncio.coroutine
def get_burger(client):
```

```
    print("    > Commande du burger en cuisine pour {}".format(client))
    yield from asyncio.sleep(3)
    print("    < Le burger de {} est prêt".format(client))

@asyncio.coroutine
def serve(client):
    print("=> Commande passée par {}".format(client))
    start_time = datetime.now()
    yield from asyncio.wait(
        [
            get_soda(client),
            get_fries(client),
            get_burger(client)
        ]
    )
    total = datetime.now() - start_time
    print("<= {} servi en {}".format(client, datetime.now() - start_time))
```

Rien de franchement dépaysant. Pour exécuter ce code, là aussi l'API est sensiblement la même que notre classe `Loop` :

```
>>> loop = asyncio.get_event_loop()
>>> loop.run_until_complete(serve("A"))
=> Commande passée par A
    > Remplissage du soda pour A
    > Commande du burger en cuisine pour A
    > Démarrage de la cuisson des frites pour A
    < Le soda de A est prêt
    < Le burger de A est prêt
    < Les frites de A sont prêtes
<= A servi en 0:00:04.003105
```

Pas d'erreur de syntaxe, le code fonctionne. On peut commencer à travailler.

Remarquons dans un premier temps que notre serveur **manque de réalisme**. En effet, si nous lui demandons de servir deux clients en même temps, voilà ce qui se produit :

```
>>> loop.run_until_complete(
...     asyncio.wait([serve("A"), serve("B")])
... )
=> Commande passée par A
=> Commande passée par B
    > Remplissage du soda pour A
    > Commande du burger en cuisine pour A
    > Démarrage de la cuisson des frites pour A
    > Démarrage de la cuisson des frites pour B
    > Remplissage du soda pour B
    > Commande du burger en cuisine pour B
    < Le soda de A est prêt
    < Le soda de B est prêt
```

```
    < Le burger de A est prêt
    < Le burger de B est prêt
    < Les frites de A sont prêtes
    < Les frites de B sont prêtes
<= A servi en 0:00:04.002609
<= B servi en 0:00:04.002792
```

Les deux commandes ont été servies simultanément, de la même façon. La préparation des trois ingrédients s'est chevauchée, comme s'il était possible de faire couler une infinité de sodas, de cuire une infinité de frites *à la demande* pour les clients, et de préparer une infinité de hamburgers en parallèle.

En bref : **notre modélisation manque de contraintes**.

Pour améliorer ce programme, nous allons modéliser les contraintes suivantes :

— La machine à sodas ne peut faire couler **qu'un seul soda à la fois**. Dans une application réelle, cela reviendrait à *requêter un service synchrone qui ne supporte pas les accès concurrents* ;
— Il n'y a que 3 cuisiniers dans le restaurant, donc **on ne peut pas préparer plus de trois hamburgers en même temps**. Dans la réalité, cela revient à *requêter un service synchrone dont trois instances tournent en parallèle* ;
— Le bac à frites s'utilise en faisant cuire 5 portions de frites d'un coup, pour servir ensuite 5 clients instantanément. Dans la réalité, cela revient, à peu de choses près, à *simuler un service synchrone qui fonctionne avec un cache.*

La machine à soda est certainement la plus simple. Il est possible de verrouiller une ressource de manière à ce qu'une seule tâche puisse y accéder à la fois, en utilisant ce que l'on appelle un **verrou** (`asyncio.Lock`). Plaçons un verrou sur notre machine à soda :

```
SODA_LOCK = asyncio.Lock()

@asyncio.coroutine
def get_soda(client):
    # Acquisition du verrou
    with (yield from SODA_LOCK):
        # Une seule tâche à la fois peut exécuter ce bloc
        print("    > Remplissage du soda pour {}".format(client))
        yield from asyncio.sleep(1)
        print("    < Le soda de {} est prêt".format(client))
```

Le `with (yield from SODA_LOCK)` signifie que lorsque le serveur arrive à la machine à soda pour y déposer un gobelet :

— soit la machine est libre (déverrouillée), auquel cas il peut la verrouiller pour l'utiliser immédiatement,
— soit celle-ci est déjà en train de fonctionner, auquel cas il attend que le soda en cours de préparation soit prêt avant de verrouiller la machine à son tour.

Passons à la cuisine. Seuls 3 burgers peuvent être fabriqués en même temps. Cela peut se modéliser en utilisant un **sémaphore** (`asyncio.Semaphore`), qui est une sorte de "verrou multiple". On l'utilise pour qu'au plus N tâches puissent exécuter un morceau de code à un instant donné.

```
BURGER_SEM = asyncio.Semaphore(3)
```

```
@asyncio.coroutine
def get_burger(client):
    print("    > Commande du burger en cuisine pour {}".format(client))
    with (yield from BURGER_SEM):
        yield from asyncio.sleep(3)
        print("    < Le burger de {} est prêt".format(client))
```

Le `with (yield from BURGER_SEM)` veut dire que lorsqu'une commande est passée en cuisine :

— soit il y a un cuisinier libre, et celui-ci commence immédiatement à préparer le hamburger,
— soit tous les cuisiniers sont occupés, auquel cas on attend qu'il y en ait un qui se libère pour s'occuper de notre hamburger.

Passons enfin au bac à frites. Cette fois, `asyncio` ne nous fournira pas d'objet magique, donc il va nous falloir réfléchir un peu plus. Il faut que l'on puisse l'utiliser *une fois* pour faire les frites des 5 prochaines commandes. Dans ce cas, un compteur semble une bonne idée :

— Chaque fois que l'on prend une portion de frites, on décrémente le compteur ;
— S'il n'y a plus de frites dans le bac, il faut en refaire.

Mais attention, si les frites sont déjà en cours de préparation, il est inutile de lancer une nouvelle fournée !

Voici comment on pourrait s'y prendre :

```
FRIES_COUNTER = 0
FRIES_LOCK = asyncio.Lock()

@asyncio.coroutine
def get_fries(client):
    global FRIES_COUNTER
    with (yield from FRIES_LOCK):
        print("    > Récupération des frites pour {}".format(client))
        if FRIES_COUNTER == 0:
            print("   ** Démarrage de la cuisson des frites")
            yield from asyncio.sleep(4)
            FRIES_COUNTER = 5
            print("   ** Les frites sont cuites")
        FRIES_COUNTER -= 1
        print("    < Les frites de {} sont prêtes".format(client))
```

Dans cet exemple, on place un verrou sur le bac à frites pour qu'un seul serveur puisse y accéder à la fois. Lorsqu'un serveur arrive devant le bac à frites, soit celui-ci contient encore des portions de frites, auquel cas il en récupère une et retourne immédiatement, soit le bac est vide, donc le serveur met des frites à cuire avant de pouvoir en récupérer une portion.

À l'exécution :

```
>>> loop.run_until_complete(asyncio.wait([serve('A'), serve('B')]))
=> Commande passée par B
=> Commande passée par A
    > Remplissage du soda pour B
    > Récupération des frites pour B
```

```
   ** Démarrage de la cuisson des frites
    > Commande du burger en cuisine pour B
    > Commande du burger en cuisine pour A
    < Le soda de B est prêt
    > Remplissage du soda pour A
    < Le soda de A est prêt
    < Le burger de B est prêt
    < Le burger de A est prêt
   ** Les frites sont cuites
    < Les frites de B sont prêtes
    > Récupération des frites pour A
    < Les frites de A sont prêtes
<= B servi en 0:00:04.003111
<= A servi en 0:00:04.003093
```

Nos deux tâches prennent toujours le même temps à s'exécuter, mais s'arrangent pour ne pas accéder simultanément à la machine à sodas ni au bac à frites.

Voyons maintenant ce que cela donne si 10 clients passent commande en même temps :

```
>>> loop.run_until_complete(
...     asyncio.wait([serve(clt) for clt in 'ABCDEFGHIJ'])
... )
...
# ... sortie filtrée ...
<= C servi en 0:00:04.004512
<= D servi en 0:00:04.004378
<= E servi en 0:00:04.004262
<= F servi en 0:00:06.008072
<= A servi en 0:00:06.008074
<= G servi en 0:00:08.006399
<= H servi en 0:00:09.009187
<= B servi en 0:00:09.009118
<= I servi en 0:00:09.015023
<= J servi en 0:00:12.011539
```

On se rend compte que les performances de notre serveur de fast-food se dégradent : certains clients attendent jusqu'à trois fois plus longtemps que les autres.

Cela n'a rien de surprenant. En fait, les performances d'une application asynchrone ne se mesurent pas en *nombre de tâches traitées simultanément*, mais plutôt, comme n'importe quel serveur, en *nombre de tâches traitées dans le temps*. Il est évident que si 10 clients viennent manger dans un fast-food, il y a relativement peu de chances qu'ils arrivent tous en même temps : ils vont plutôt passer leur commande à raison d'une par seconde, par exemple.

Par contre, il est très important de noter que c'est bien *le temps d'attente* individuel de chaque client qui compte pour mesurer les performances (la qualité) du service. Si un client attend trop longtemps, il ne sera pas satisfait, peu importe s'il est tout seul dans le restaurant ou que celui-ci est bondé.

Pour ces raisons, il faut que nous ayons une idée des **objectifs de performances** de notre serveur, c'est-à-dire que nous fixions, comme but :

— un *temps d'attente maximal* à ne pas dépasser pour servir un client,
— un *volume* de requêtes à tenir par seconde.

Écrivons maintenant une coroutine pour tester les performances de notre serveur :

```
# La fonction ensure_future est définie à partir de Python 3.4.4
# Ce bloc la rend accessible pour toutes les versions de Python 3.4
try:
    from asyncio import ensure_future
except ImportError:
    asyncio.ensure_future = asyncio.async

@asyncio.coroutine
def perf_test(nb_requests, period, timeout):
    tasks = []
    # On lance 'nb_requests' commandes à 'period' secondes d'intervalle
    for idx in range(1, nb_requests + 1):
        client_name = "client_{}".format(idx)
        tsk = asyncio.ensure_future(serve(client_name))
        tasks.append(tsk)
        yield from asyncio.sleep(period)

    finished, _ = yield from asyncio.wait(tasks)
    success = set()
    for tsk in finished:
        if tsk.result().seconds < timeout:
            success.add(tsk)

    print("{}/{} clients satisfaits".format(len(success), len(finished)))
```

Cette coroutine va lancer un certain nombre de commandes, régulièrement, et compter à la fin le nombre de commandes qui ont été honorées dans les temps.

Essayons de lancer 10 commandes à 1 seconde d'intervalle, avec pour objectif que les clients soient servis en 5 secondes maximum :

```
>>> loop.run_until_complete(perf_test(10, 1, 5))
# ... sortie filtrée ...
<= client_1 servi en 0:00:04.004044
<= client_2 servi en 0:00:03.002792
<= client_3 servi en 0:00:03.003338
<= client_4 servi en 0:00:03.003653
<= client_5 servi en 0:00:03.003815
<= client_6 servi en 0:00:04.003746
<= client_7 servi en 0:00:03.003412
<= client_8 servi en 0:00:03.002512
<= client_9 servi en 0:00:03.003409
<= client_10 servi en 0:00:03.003622
10/10 clients satisfaits
```

Ce test nous indique que notre serveur tient facilement une charge d'un client par seconde. Essayons

de monter en charge en passant à deux clients par seconde :

```
>>> loop.run_until_complete(perf_test(10, 0.5, 5))
# ... sortie filtrée ...
<= client_1 servi en 0:00:04.002629
<= client_2 servi en 0:00:03.502093
<= client_3 servi en 0:00:03.002863
<= client_4 servi en 0:00:04.500168
<= client_5 servi en 0:00:04.500226
<= client_6 servi en 0:00:05.499894
<= client_7 servi en 0:00:05.999704
<= client_8 servi en 0:00:05.998824
<= client_9 servi en 0:00:05.999883
<= client_10 servi en 0:00:07.498776
5/10 clients satisfaits
```

À deux clients par seconde, notre serveur n'offre plus de performances satisfaisantes pour la moitié des commandes.

Nous pouvons donc poser le problème d'optimisation suivant : le gérant du restaurant veut devenir capable de servir 2 clients par seconde avec un temps de traitement inférieur à 5 secondes par commande. Pour cela, il peut :

— Acheter de nouvelles machines à sodas ;
— Embaucher de nouveaux cuisiniers ;
— Remplacer son bac à frites (capable de cuire 5 portions en 4 secondes) par un nouveau, qui peut faire cuire 7 portions en 4 secondes.

Évidemment, chacune de ces solutions a un coût, donc il est préférable pour le gérant de n'apporter que le moins possible de modifications pour tenir son objectif. Si l'on voulait faire un parallèle avec une application réelle :

— Acheter une seconde machine à sodas coûterait l'occupation à 100% d'un cœur de CPU supplémentaire + une augmentation de 100% de la RAM consommée par le service "soda".
— Embaucher un quatrième cuisinier coûterait un cœur de CPU supplémentaire + une augmentation de 33% de la RAM consommée par le service "cuisine".
— Le remplacement du bac à frites augmenterait uniquement de 40% la consommation de RAM de ce service...

En guise d'exercice, vous pouvez vous amuser à modifier les contraintes de notre programme en conséquence pour observer l'impact de vos modifications sur les performances du serveur : vous vous trouverez alors véritablement dans la peau d'un architecte système, le salaire et le stress en moins. ;)

Exemple n°5 : Les entrées/sorties, le nerf de la guerre

Vous vous demandez peut-être pourquoi on parle tout le temps d'*IO* en programmation asynchrone. En effet, les entrées/sorties des programmes semblent indissociables du concept d'asynchrone, à tel point que cela se traduit jusque dans le nom de la bibliothèque standard `asyncio` de Python. Mais *pourquoi* ?

Commençons par une définition : une *IO*, c'est une opération pendant laquelle un programme *interagit avec un flux de données*. Ce **flux de données** peut être plein de choses : une connexion réseau, les flux standard `STDIN`, `STDOUT` ou `STDERR` du processus en cours d'exécution, un fichier, ou même une abstraction matérielle[5]. « Interagir avec un flux de données », ça veut dire l'**ouvrir**, **lire** ou **écrire** dedans ou le **fermer**.

Jusqu'ici, nous avons travaillé sur des exemples très simples qui se contentaient d'afficher des choses à l'écran pour bien comprendre l'ordre dans lequel les instructions étaient exécutées. Nos tâches ne réalisaient du coup que des entrées/sorties, certes, mais celles-ci étaient *synchrones* : on a considéré jusqu'à maintenant qu'un `print()` dans la console s'exécute immédiatement et sans délai lors de son appel, ce qui est parfaitement intuitif...

... mais pas toujours le reflet de la réalité.

Prenons par exemple une IO très simple que vous réalisez en permanence sur votre ordinateur ou smartphone sans même vous en rendre compte : **que se passe-t-il entre le moment où vous avez cliqué sur un lien dans une page web, et celui où le résultat commence à s'afficher sur votre écran** ?

Eh bien vous **attendez**. Tout simplement. Et votre navigateur aussi. Sans rentrer dans le détail du protocole HTTP, on peut schématiser grossièrement ce qui se passe comme ceci :

```
        Navigateur                          Serveur web
        ==========                          ===========

           [clic sur le lien]                     .
[création d'une requête HTTP]                     .
       [connexion au serveur]  ------>            .
            .                                [connexion reçue]
            .                  <------       [connexion acceptée]
        [envoi de la requête]  ------>            .
            .                                [réception de la requête]
            .                                [création de la réponse]
            .                  <------       [envoi de la réponse]
    [réception de la réponse]                       .
       [affichage de la page]
```

Dans ce schéma, tous les points (`.`) symbolisent une attente. Un échange HTTP (et plus généralement une IO), c'est une opération pendant laquelle les programmes, passent le plus clair de leur temps à **ne rien faire**. Et votre navigateur lui-même vous le dit (généralement dans un petit cadre en bas à gauche de l'écran) :

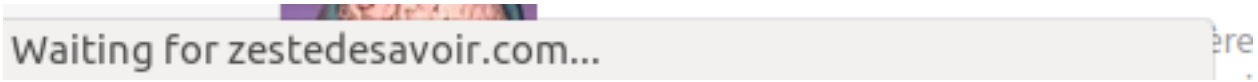

Dans ces conditions, l'idée de base de la programmation asynchrone est de *mettre à profit* tout ce temps que l'on passe à attendre pendant la réalisation d'une IO pour **s'occuper en faisant autre chose**.

5. On peut par exemple lire un son sous Linux en *écrivant* des données dans un fichier spécial qui représente la carte son !

L'exemple du serveur de *fast food* que nous avons modélisé plus tôt n'est pas anodin ; qu'il s'agisse du serveur *bien réel* d'un restaurant ou celui d'une application réseau, les deux réalisent en général des opérations comparables. En effet, de très nombreux serveurs (par exemple d'applications Web) fonctionnent plus ou moins suivant ce schéma :

1. Recevoir une requête, une commande ou un message,
2. Aller récupérer des ressources à différents endroits,
3. Combiner les ressources entre elles,
4. Répondre au client.

Dans ce schéma, les points 1, 2 et 4 peuvent être des *IO* :

1. Réception :
   — **Attente** d'une connexion,
   — Acceptation de la connexion,
   — **Attente** du message,
   — Réception du message
2. Récupérer des ressources :
   — S'il s'agit de ressources distantes :
      — Connexion à un service,
      — **Attente** de l'acceptation de la connexion,
      — Envoi d'une requête,
      — **Attente** que la réponse arrive,
      — Réception de la réponse,
   — Si la ressource est protégée par un verrou ou un sémaphore :
      — **Attente** de l'acquisition du verrou/sémaphore,
      — Récupération de la ressource,
      — Relâchement du verrou/sémaphore,
3. Combiner les ressources entre elles,
4. Répondre au client :
   — **Attente** que le *medium* soit disponible en écriture,
   — Envoi de la réponse.

Comme vous le voyez, il est vraiment *très* courant d'attendre pour un serveur. Et il ne s'agit là que d'un schéma particulier dans une infinité d'applications possibles.

Ainsi, il serait possible d'optimiser de nombreux programmes en les rendant asynchrones, pour peu que l'on soit capable de rendre leurs *IO* **non bloquantes**, c'est-à-dire que l'on puisse laisser la main à d'autres tâches au lieu d'attendre, et reprendre celle-ci avec l'assurance que l'on pourra réaliser une *IO* immédiatement.

Il existe sous la plupart des systèmes d'exploitation une fonctionnalité qui permet de déterminer à un instant donné si un ou plusieurs flux de données sont accessibles en lecture ou en écriture. En fait, il en existe plein, mais nous allons nous concentrer sur celle qui sera disponible sur la plupart des systèmes d'exploitation : il s'agit de l'appel-système `select()`.

Celui-ci, en Python, se présente sous la forme suivante :

```
select.select(rlist, wlist, xlist[, timeout])
```

Où :

— `rlist` est une liste de flux sur lesquels nous voulons lire des données,
— `wlist` est une liste de flux dans lesquels nous voulons écrire des données,
— `xlist` est une liste de flux que l'on surveille jusqu'à ce qu'il se produise des *conditions exceptionnelles* (ne nous attardons pas là-dessus),
— `timeout` est une durée (optionnelle) pendant laquelle on attend que des flux soient disponibles. Par défaut, on attend indéfiniment. Si on lui passe la valeur `0`, l'appel à `select()` retourne immédiatement.

Cette fonction retourne trois listes :

— une contenant les flux disponibles en lecture à l'instant T,
— une contenant les flux disponibles en écriture à l'instant T,
— une autre contenant les flux victimes d'une exception.

Que demander de plus ? Nous avons à notre disposition une fonction, dont l'exécution est instantannée, qui pourra nous permettre de réveiller les tâches en attente de lecture ou d'écriture.

On peut donc implémenter les coroutines d'attente asynchrones suivantes :

```
from select import select

# Attendre de façon asynchrone qu'un flux soit disponible en lecture
def wait_readable(stream):
    while True:
        rlist, _, _ = select([stream], [], [], 0)
        if rlist:
            return stream
        yield

# Attendre de façon asynchrone qu'un flux soit disponible en écriture
def wait_writable(stream):
    while True:
        _, wlist, _ = select([], [stream], [], 0)
        if wlist:
            return stream
        yield
```

Note : Sous la plupart des systèmes d'exploitation Unix, vous pouvez utiliser `select()` pour attendre après n'importe quel flux de données (flux standard, fichiers, sockets), mais sous Windows, *seules* les sockets sont supportées.

Pour bien comprendre l'apport de ces deux fonctions, commençons par écrire un petit serveur qui se contente d'attendre une seconde avant de renvoyer les messages des clients :

```
from socket import socket
from time import sleep

def echo_server():
    # On crée une socket (par défaut : TCP/IP)
    # qui écoutera sur le port 1234
    sock = socket()
    sock.bind(('localhost', 1234))
```

```
    # On garde un maximum de 5 demandes de connexion en attente
    sock.listen(5)
    try:
        while True:
            # Acceptation de la connection
            conn, host = sock.accept()

            # Réception d'un message (4 Mio max.)
            msg = conn.recv(4096)
            print("message reçu de {!r}: {}".format(host, msg.decode()))
            sleep(1)

            # Renvoi du message
            conn.send(msg)
            conn.close()
    finally:
        sock.close()
```

Lançons ce serveur dans une console.

```
>>> echo_server()
```

Dans **une autre console**, nous pouvons vérifier que celui-ci fonctionne en lui envoyant un message.

```
>>> sock = socket.socket()
>>> sock.connect(('localhost', 1234))
>>> sock.send("Ohé !".encode())
6
```

Le serveur affiche alors :

```
message reçu de ('127.0.0.1', 40568): Ohé !
```

Nous n'avons plus qu'à récupérer sa réponse dans la fenêtre du client :

```
>>> data = sock.recv(1024)
>>> data.decode()
'Ohé !'
```

Parfait.

Pour corser les choses, essayons maintenant de lui envoyer 5 messages à la fois. Utilisons pour cela `asyncio`, ainsi que les deux coroutines d'attente que nous venons d'écrire :

```
from socket import socket
from datetime import datetime

@asyncio.coroutine
def echo(msg):
    # Connection TCP au port 1234
```

```
    sock = socket()
    sock.connect(('localhost', 1234))

    # On attend de pouvoir envoyer le message
    yield from wait_writable(sock)
    print("Envoi du message {!r}".format(msg))
    sock.send(msg.encode())

    # On attend la réponse
    yield from wait_readable(sock)
    data = sock.recv(4096)
    print("Message reçu:", data.decode())
    sock.close()

@asyncio.coroutine
def echo_client():
    start = datetime.now()
    tasks = [echo("Hello {}".format(num)) for num in range(5)]
    yield from asyncio.wait(tasks)
    print("temps total:", datetime.now() - start)
```

Rien de fondamentalement compliqué : la coroutine `echo()` se contente de faire ce que nous avons réalisé juste avant dans la console, mais en attendant de façon asynchrone que la socket soit disponible en écriture, puis en lecture.

Voici le résultat :

```
>>> loop = asyncio.get_event_loop()
>>> loop.run_until_complete(echo_client())
Envoi du message 'Hello 2'
Envoi du message 'Hello 1'
Envoi du message 'Hello 0'
Envoi du message 'Hello 3'
Envoi du message 'Hello 4'
Message reçu: Hello 2
Message reçu: Hello 1
Message reçu: Hello 0
Message reçu: Hello 3
Message reçu: Hello 4
temps total: 0:00:05.013461
```

À l'exécution, nous nous rendons compte que le serveur, qui est *synchrone*, traite les messages les uns à la suite des autres. Réimplémentons-le avec `asyncio` :

```
from socket import socket
import asyncio

@asyncio.coroutine
def serve_echo(conn, host):
    # On suspend l'exécution jusqu'à recevoir un message
```

```
    yield from wait_readable(conn)
    msg = conn.recv(4096)
    print("message reçu de {!r}: {}".format(host, msg.decode()))
    yield from asyncio.sleep(1)

    # On suspend l'exécution jusqu'à pouvoir répondre au client
    yield from wait_writable(conn)
    conn.send(msg)
    conn.close()

@asyncio.coroutine
def echo_server():
    # On crée une socket (par défaut : TCP/IP)
    # qui écoutera sur le port 1234
    sock = socket()
    sock.bind(('localhost', 1234))

    # On garde un maximum de 5 demandes de connexion en attente
    sock.listen(5)
    try:
        while True:
            # On attent qu'une demande de connexion arrive
            yield from wait_readable(sock)

            # Acceptation de la connection
            conn, host = sock.accept()

            # On programme le traitement de la requête dans une tâche séparée.
            asyncio.async(serve_echo(conn, host))
    finally:
        sock.close()
```

Lançons le serveur :

```
>>> loop = asyncio.get_event_loop()
>>> loop.run_until_complete(echo_server())
```

Puis le client :

```
>>> loop.run_until_complete(echo_client())
Envoi du message 'Hello 3'
Envoi du message 'Hello 0'
Envoi du message 'Hello 2'
Envoi du message 'Hello 1'
Envoi du message 'Hello 4'
Message reçu: Hello 3
Message reçu: Hello 0
Message reçu: Hello 2
Message reçu: Hello 1
```

```
Message reçu: Hello 4
temps total: 0:00:01.001991
```

Cette fois-ci, le serveur a traité toutes les requêtes en même temps, pour un temps d'exécution total de 1s au lieu de 5s.

Nous voici maintenant capables de réaliser des *IO* asynchrones ! Néanmoins, bien que nos coroutines `wait_readable()` et `wait_writable()` soient tout à fait fonctionnelles dans cet exemple, je vous **déconseille très vivement** de les utiliser. En effet, celles-ci bouclent à l'infini jusqu'à ce que le flux soit disponible, au lieu d'attendre passivement sans consommer de temps sur le processeur.

Rassurez-vous, `asyncio` propose de nombreuses façons de réaliser la même chose, et ce sans surcharger le processeur. Nous les examinerons dans les exemples suivants.

Exemple n°6 : Des applications réseau avec `asyncio`

Le précédent exemple nous a fait toucher du doigt le concept d'*IO asynchrones*. Il est temps pour nous de nous familiariser avec les objets que nous propose `asyncio` pour réaliser de telles opérations sur un flux réseau.

Commençons par examiner un exemple que nous détaillerons ensuite. Voici le client du précédent exemple, réimplémenté avec les outils d'`asyncio` :

```
@asyncio.coroutine
def echo_client(message):
    reader, writer = yield from asyncio.open_connection('localhost', 1234)

    print("Envoi du message :", message)
    writer.write(message.encode())

    data = yield from reader.read(1024)
    print("Message reçu :", data.decode())

    writer.close()
```

Même sans savoir ce que sont ces objets `reader` et `writer`, la lecture de ce code est plutôt intuitive :

- La coroutine `ayncio.open_connection()` crée une connexion et retourne deux objets :
  - Un "*reader*" que l'on peut utiliser pour recevoir des données,
  - Un "*writer*" dont on se sert pour en envoyer,
- On se sert du `writer` pour envoyer un message au serveur (attention : la méthode `write()` est une fonction et non une coroutine ; pas de `yield from`),
- On appelle ensuite, cette fois de façon asynchrone, la méthode `reader.read()` pour récupérer des données (on s'attend à moins de 1024 octets),
- On ferme le `writer` pour clore la connexion.

Avant d'aller plus loin, lançons le serveur de l'exemple précédent et vérifions que ce code fonctionne dans la console :

```
>>> import asyncio
>>> loop = asyncio.get_event_loop()
```

```
>>> loop.run_until_complete(echo_client("Coucou!"))
Envoi du message : Coucou!
Message reçu : Coucou!
```

Par de surprise, le code se comporte comme prévu. Attardons-nous un peu sur ces fameux objets qu'`asyncio` a créés pour nous. Il s'agit en fait d'instances de `asyncio.StreamReader` et `asyncio.StreamWriter`.

Il s'agit de l'interface haut niveau d'asyncio pour manipuler une connexion de type "*Stream*" (typiquement, TCP). La même interface existe également pour les sockets Unix. Ces objets représentent un les deux sens d'un même flux réseau. Ainsi, vous avez grosso-modo 4 méthodes à retenir :

— La *coroutine* `StreamReader.read(size)` sert à recevoir un bloc de `size` octets de données maximum, de façon asynchrone ;
— La *coroutine* `StreamReader.readline()` sert à recevoir une "ligne" de données, terminée par le caractère ASCII spécial *LINE_FEED* (`'\n'`) ;
— La *fonction* `StreamWriter.write(data)` sert à envoyer des données (sous la forme d'un objet `bytes`) sur le flux. En fait, les données seront placées en attente dans un tampon (*buffer*) qui ne sera vidé qu'au prochain `yield`...
— Ce qui nous amène à la *coroutine* `StreamWriter.drain()`, qui sert à vider explicitement le tampon du *writer* pour envoyer les données sur le flux.

C'est plutôt simple, non ? Ces objets reposent en fait sur une autre API, un petit peu plus bas niveau, d'`asyncio`, qui modélise des *protocoles* que l'on utilise par-dessus un *transport* (TCP, UDP...). Nous ne parlerons pas de cette API dans cet exemple, mais si vous êtes curieux, sa documentation est plutôt claire et détaillée.

Cette même interface peut d'ailleurs nous permettre de créer facilement un serveur, au moyen de la coroutine `asyncio.start_server()` :

```
#!/usr/bin/env python3
import asyncio

@asyncio.coroutine
def handle_echo(reader, writer):
    data = yield from reader.read(1024)
    print("Message reçu :", data.decode())
    yield from asyncio.sleep(1)
    writer.write(data)
    yield from writer.drain()
    writer.close()

def echo_server():
    loop = asyncio.get_event_loop()
    server = loop.run_until_complete(
        asyncio.start_server(handle_echo, 'localhost', 1234)
    )

    try:
        loop.run_forever()
    except KeyboardInterrupt:
```

```
        pass

    server.close()
    loop.run_until_complete(server.wait_closed())
    loop.close()

if __name__ == '__main__':
    echo_server()
```

Ici, tout le code de notre serveur se trouve dans la coroutine `handle_echo`. Cette coroutine accepte un `StreamReader` et un `StreamWriter`, et ne retourne que lorsque l'échange avec un client est terminé.

Dans la fonction `echo_server()` on commence par créer un serveur en passant cette coroutine à `asyncio.start_server()` dans la boucle événementielle, puis on demande à la boucle de tourner "à l'infini" (jusqu'à ce que le processus soit interrompu).

Notez que nous aurions pu instancier le même service, mais sur des sockets Unix au lieu d'un flux TCP, simplement en utilisant la fonction `asyncio.start_unix_server()` à la place de `asyncio.start_server()` : la coroutine `handle_echo`, restera la même, et sera lancée dans une nouvelle tâche chaque fois qu'un client se connectera.